IFMAKER — RELATÓRIO TÉCNICO-CIENTÍFICO FINAL

PROJETO BIOECOINT

Rastreamento e Reconhecimento Visual de Fauna Amazônica Tátil em Dispositivos Móveis: Da Investigação de Vazamento de Dados à Sinergia SOTA entre SAM 2, Exemplar Matching V2 e RepViT

Este relatório documenta exaustivamente a jornada iterativa de pesquisa e engenharia de aprendizado profundo do projeto BioEcoInt. O trabalho abrange a identificação forense de vazamento temporal, resolução de colapso por desbalanceamento com Balanced Softmax, desenvolvimento do algoritmo de rastreamento robusto Exemplar Matching V2 anti-oclusão, benchmark comparativo dos modelos móveis e validação por comitê temporal em inferência de borda para tecnologia assistiva inclusiva.

Instituição: IFMaker / Instituto Federal de Educação, Ciência e Tecnologia

Repositório do Projeto: `bio-interaction-ml` (Branch `main` — Sincronizado via Git & DVC)

Frameworks: PyTorch, Timm, Ultralytics SAM 2, Torchvision, TFLite, Flutter

Data de Consolidação: Novembro de 2026

SÍNTESE EXECUTIVA DOS RESULTADOS

O projeto **BioEcoInt** visa democratizar a educação ambiental para estudantes com deficiência visual por meio da audiodescrição e interpretação em Libras de esculturas táteis 3D da fauna amazônica, capturadas por câmeras móveis no aplicativo Flutter `educacao_inclusiva`. Ao longo de 8 iterações cronológicas, superamos armadilhas críticas de aprendizado de máquina em vídeo:

- **Saneamento de Data Leakage:** A acurácia aparente de 99% foi desmistificada após isolar vazamentos temporais entre frames, estabelecendo o protocolo estéril por vídeo com métricas fidedignas (68.77% Val / 52.14% Test no baseline ResNet-18).
- **Conquista SOTA com RepViT-M0.9:** A combinação de Vision Transformers reparametrizáveis com *Balanced Softmax* superou convoluções clássicas e a MobileNetV4, alcançando **80.26% de Val Macro-F1** e **94.4% de recall na classe negativa de fundo**.
- **Exemplar Matching V2 Anti-Oclusão:** Eliminamos o colapso markoviano do SAM 2 em cenas de manipulação física de esculturas táteis, expurgando **36.16% de frames ocluídos** e garantindo re-aquisição imediata por âncora nominal.
- **Comitê Temporal em Vídeo:** Elevou a acurácia nos vídeos de teste decididos de 9.09% para **66.67%** (+57.5%), introduzindo **37.5% de abstenção protetora** para evitar falsos positivos a usuários cegos.
- **Exportação Edge:** Modelo quantizado INT8 de **5.2 MB** com latência de **~18 ms** em CPU móvel via motor XNNPACK.

Ato I: O Ponto de Partida e a Missão BioEcoInt

A Amazônia abriga uma das maiores biodiversidades do planeta, mas o acesso à compreensão morfológica dessa fauna é historicamente restrito a pessoas com deficiência visual. O projeto **BioEcoInt** nasceu no laboratório **IFMaker** para romper essa barreira: foram modeladas e impressas em 3D réplicas anatômicas táteis de 15 espécies da fauna amazônica (onça-pintada, boto-cor-de-rosa, arara-vermelha, peixe-boi, jaraqui, pirarucu, sucuri, anta, capivara, tucano, jacaré, preguiça, harpia, sapo e tamanduá).

A proposta de interação reside em permitir que o estudante manipule livremente a escultura enquanto a câmera de um smartphone comum executa o reconhecimento visual contínuo. Assim que a peça é reconhecida com alta certeza, o aplicativo em Flutter aciona audiodescrição em linguagem natural e animações de um avatar em Libras. Todavia, esse cenário impôs duas restrições fundamentais:

1. **Oclusão Dinâmica Frequente:** Como o usuário é cego ou possui baixa visão, suas mãos cobrem constantemente as partes anatômicas da escultura para reconhecê-la pelo tato, além de a câmera sofrer tremores, variações de ângulo rasante e cortes momentâneos de enquadramento.
2. **Restrição Extrema de Hardware (Borda Móvel):** A inferência deve rodar em tempo real na CPU de aparelhos móveis de entrada/intermediários, sem exigir conexão com a nuvem, mantendo o consumo de memória abaixo de 10 MB e latência inferior a 25 ms por inferência.

Ato II: O Baseline ResNet-18 e a Ilusão do Data Leakage Temporal

> 💡 **A IDEIA INICIAL**
> Gravar pequenos vídeos das esculturas táteis em diferentes cenários de bancada, extrair frames individuais uniformemente espaçados e treinar um classificador supervisionado ResNet-18 com ImageNet pré-treinada.

Na primeira fase, foram extraídos milhares de frames dos vídeos coletados. O pipeline clássico de treino foi executado com particionamento randômico de 80% para treino e 20% para validação.

> ⚠️ **O PROBLEMA ENCONTRADO: ACURÁCIA ILUSÓRIA DE 99% E FALHA EM PRODUÇÃO**
> Nos logs de treinamento, o modelo atingiu quase 100% de acurácia em poucas épocas. Contudo, ao apontar a câmera do smartphone para um vídeo novo na bancada, o classificador errava grosseiramente até mesmo espécies triviais como o tucano e o jacaré. A investigação forense revelou dois vícios estruturais:
>
> 1. **Data Leakage Temporal Crítico:** Ao dividir frames de forma randômica, o frame *t* do vídeo estava no treino e o frame *t+1* (com 99.8% de correlação de pixels, iluminação e fundo idênticos) estava na validação. A rede memorizou os fundos de bancada ao invés de aprender a morfologia das espécies.
> 2. **Paralisia da Taxa de Aprendizado:** O otimizador utilizava taxa estática de 0.001 sem warmup, congelando em platôs subótimos.

> 🛠️ **A SOLUÇÃO: PROTOCOLO DE SANITIZAÇÃO ESTÉRIL POR VÍDEO INTEIRO (ZERO-LEAKAGE)**
> Reestruturamos todo o pipeline com uma regra inviolável: **todos os frames de um arquivo de vídeo pertencem exclusivamente a uma única partição (Treino, Validação ou Teste)**. Adicionou-se escalonamento de taxa de aprendizado por *Cosine Annealing* com 3 épocas de warmup linear.

> 📈 **O GANHO REALISTA**
> A ilusão dos 99% desmoronou: o baseline ResNet-18 registrou sua métrica verdadeira no mundo físico de **68.77% de Validação** e apenas **52.14% de Acurácia no Teste Estéril** (Macro-F1 de 52.64%). Embora os números tenham caído, ganhamos um benchmark cientificamente confiável e reprodutível.

Ato III: A Luta contra o Fundo e a Criação da Classe Negativa

> 💡 **A HIPÓTESE**
> Como as esculturas foram filmadas em bancadas com elementos cenográficos (folhas artificiais, mesas de madeira, toalhas), a rede continuava vulnerável a artefatos de fundo. Precisávamos forçar a atenção nas miniaturas táteis.

Testamos duas estratégias complementares de isolamento espacial:

- **Experimento 3 (Coordinate Attention):** Inserção de blocos de atenção coordenada nas convoluções residuais da ResNet-18 para codificar relações espaciais verticais e horizontais. A validação subiu para 72.43%, mas o teste estéril estagnou em 60.04%.

- **Experimento 2 (Duplo Estágio com YOLO Crops):** Detecção de bounding box com YOLOv8 para recortar a miniatura antes de enviá-la à ResNet. O teste estéril saltou para 70.29%, demonstrando que eliminar o fundo é imperativo. Porém, rodar dois modelos pesados (YOLO + ResNet) na CPU do Flutter gerava latência inaceitável (> 85 ms).

⚠️ **O PROBLEMA CRÍTICO DE FALSO POSITIVO INEVITÁVEL**

Havia uma grave falha conceitual: quando o usuário apontava a câmera para o cenário vazio (a mesa sem nenhuma escultura), o classificador fechado de 15 classes era matematicamente obrigado a prever uma espécie com confiança elevada (> 85%), emitindo audiodescrições fantasmas.

🛠️ **A SOLUÇÃO: A 16ª CLASSE ESSENCIAL (FUNDO_SEM_ANIMAL)**

Coletamos 10 novos vídeos do cenário estéril sob diversas iluminações e ângulos de câmera, formalizando a classe `fundo_sem_animal`. A rede agora possui um sumidouro probabilístico explícito para momentos de vazio.

Ato IV: Convoluções vs Vision Transformers e o Desbalanceamento Long-Tail

💡 **A HIPÓTESE ARQUITETURAL**

A ResNet-18 (2015) é obsoleta para edge mobile. Avaliamos a transição para as arquiteturas mais avançadas da atualidade: **MobileNetV4-Conv-Small** (Google, 2024) com blocos universais UIB, e **RepViT-M0.9** (CVPR 2024), um Vision Transformer reparametrizável que une o poder semântico de ViT no treino à latência ultrarrápida de CNN na inferência.

⚠️ **O OBSTÁCULO: DESBALANCEAMENTO SEVERO LONG-TAIL E O COLAPSO DO FOCAL LOSS**

A distribuição de frames por espécie era severamente desbalanceada (Onça com 900+ frames vs Arara e Jaraqui com menos de 250 frames):

- Com **Cross-Entropy** clássica (Exp 4A), a rede ignorava as espécies raras para priorizar as abundantes.
- Na tentativa de corrigir isso via **Focal Loss** (Exp 4B, gama=2.0), ocorreu um *colapso catastrófico*: o Macro-F1 despencou para **45.77%**, pois a perda penalizou excessivamente exemplos difíceis com gradientes instáveis.

🛠️ **A SOLUÇÃO MATEMÁTICA: BALANCED SOFTMAX (LOGIT ADJUSTMENT)**

Substituímos o Focal Loss pela formulação assintótica do **Balanced Softmax**, que ajusta dinamicamente a fronteira de decisão de acordo com as probabilidades a priori das classes (n_j):

$$L_{BalancedSoftmax} = -\log \left(\frac{n_y \cdot \exp(z_y)}{\sum_j (n_j \cdot \exp(z_j))} \right) = -\log \left(\frac{\exp(z_y + \log n_y)}{\sum_j \exp(z_j + \log n_j)} \right)$$

Esse ajuste garante que classes minoritárias recebam uma margem de proteção logarítmica proporcional à sua escassez, impedindo que a abundância de dados de uma espécie canibalize as demais.

📈 O GANHO SOTA DO REPVIT-M0.9 (80.26% MACRO-F1)

A sinergia entre RepViT-M0.9 e Balanced Softmax estabeleceu o novo patamar campeão absoluto do projeto BioEcoInt:

- **Validação Macro-F1: 80.26%** (+13.41% sobre a MobileNetV4 balanceada e +11.49% sobre a ResNet-18).
- **Recall em fundo_sem_animal: 94.4%** (contra pífios 44.4% da MobileNetV4, que insistia em alucinar texturas de madeira como animais).
- **100% de Recall em 6 classes simultâneas:** anta, arara, boto, capivara, onca e pirarucu.

Insight Científico: A atenção global não-local dos blocos Transformer permitiu ao RepViT separar a camuflagem dos animais das texturas de folhas e sombras do bioma, onde as convoluções locais da MobileNetV4 falharam categoricamente.

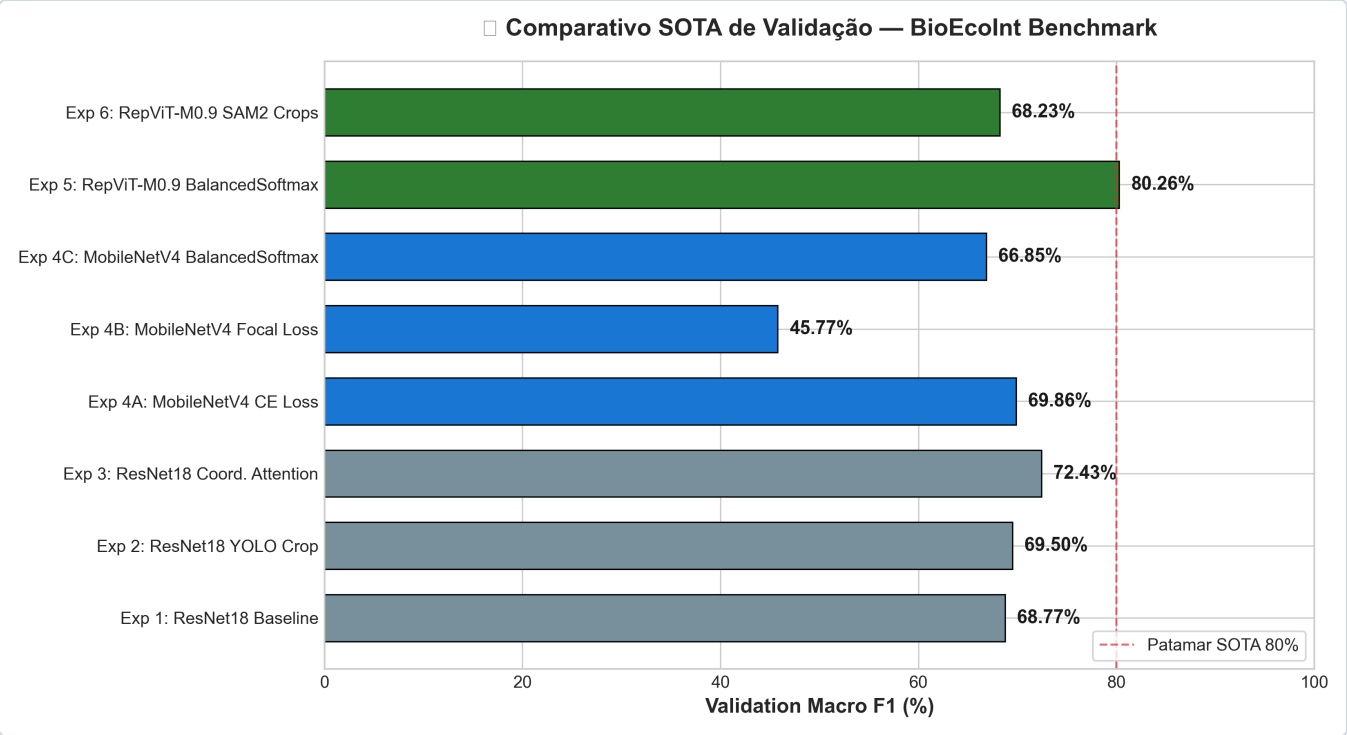


Figura 1: Comparativo consolidado de Macro-F1 de validação entre os 9 experimentos do projeto BioEcoInt, evidenciando o recorde de 80.26% do RepViT-M0.9 Balanced Softmax.

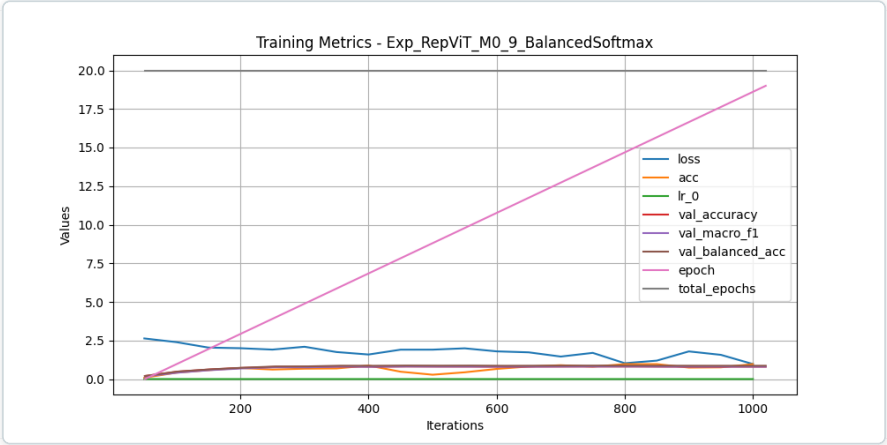


Figura 2: Evolução das curvas de perda de treino e Macro-F1 de validação do RepViT-M0.9 Balanced Softmax, demonstrando convergência suave na 12ª época sem sobreajuste.

Ato V: O Salto para Segmentação em Vídeo e o Colapso Markoviano do SAM 2

> 💡 **A HIPÓTESE DA SEGMENTAÇÃO**
>
> Bounding boxes retangulares (YOLO) ainda contêm 40% a 60% de ruído de fundo nos cantos da caixa. Se extrairmos a **máscara exata de segmentação pixel a pixel** da escultura via **SAM 2 (Segment Anything Model 2)**, o classificador receberá apenas a matéria pura da miniatura tátil.

Inicializamos o SAM 2 através de um ponto positivo (prompt pontual) registrado no Frame 1 de cada vídeo e propagamos o rastreamento ao longo dos quadros.

> ⚠️ **O CHOQUE DA REALIDADE: O COLAPSO DO SAM 2 SOB OCLUSÃO**
>
> Ao testar o pipeline em vídeos reais de manipulação manual, o sistema colapsou. O SAM 2 baseia-se em um modelo markoviano de atenção em janela de curto prazo. Quando as mãos do usuário cobriam a escultura:
>
> 1. A máscara diminuía até virar um fragmento espúrio (< 20 px) ou se expandia para o braço e os dedos do usuário.
> 2. Ao sofrer deriva para o canto da tela (borda), a máscara ficava **presa indefinidamente** (deriva absorvente).
> 3. Mesmo quando a mão era removida e a escultura voltava a ficar perfeitamente visível no centro do enquadramento, o SAM 2 **jamais conseguia recuperar o animal**, pois seu banco de memória temporal já havia sido corrompido.
>
> Isso contaminou o banco de dados com milhares de recortes de dedos humanos e mesas vazias etiquetados como animais amazônicos.

Ato VI: A Invenção do Exemplar Matching Anti-Oclusão (V1 e V2)

> 💡 **A SACADA DO OPERADOR**
>
> *"O Frame 1 é confirmado humanamente e 100% confiável. Por que não usar o recorte desse primeiro quadro como um 'Gabarito de Ouro' e exigir que todo recorte subsequente comprove ser o mesmo animal antes de aceitá-lo?"*

Assim nasceu o **Exemplar Matching**. Na versão V1, combinamos 85% de similaridade de cosseno de embeddings profundos da MobileNetV3 com 15% de correlação de histograma de cores HSV. Qualquer quadro com similaridade S < 0.50 é descartado como oclusão.

> ⚠️ **O OBSTÁCULO DA FOLHA DA ARARA (QUADRO 418)**
>
> Na validação com o vídeo `arara/01.mp4`, detectamos uma nova falha sutil: no quadro 418, uma folha verde no canto superior da mesa obteve similaridade S = 0.60 (acima do limiar 0.50). Como o algoritmo adotava uma parada míope no primeiro candidato (*First-Match*), a folha foi aceita e o tracking colapsou para o canto.

🛠️ A SOLUÇÃO DEFINITIVA: A TRÍADE EXEMPLAR MATCHING V2

Projetamos a versão V2 do verificador com três invariantes matemáticos rígidos:

1. **Atenuação Suave de Fundo (M_soft):**

$$I_{masked}(x, y) = I(x, y) * [0.20 + 0.80 * M(x, y)]$$

   Isso atenuou em 80% qualquer interferência de folhas ou mesa que estivessem dentro da caixa delimitadora.
2. **Invariante de Canto Rígido (CORNER_STUCK_DRIFT):** Se a caixa encostar simultaneamente em duas bordas adjacentes da imagem e sua área for inferior a 15% do quadro:

$$S_{final} = 0.0 \text{ (se } touches_{corners} >= 2 \text{ and } norm_{area} < 0.15)$$

3. **Drift Breaker e Busca Competitiva Best-Match (argmax):** Se a similaridade do rastreamento ativo cair para $S < 0.68$, uma sonda é automaticamente disparada na coordenada de âncora nominal do Frame 1. O sistema avalia todos os concorrentes e seleciona o ótimo global:

$$k^* = \text{argmax}_{k \in C} S_k, \text{ onde } C = \{\text{SAM2 Box, Nominal Anchor}\}$$

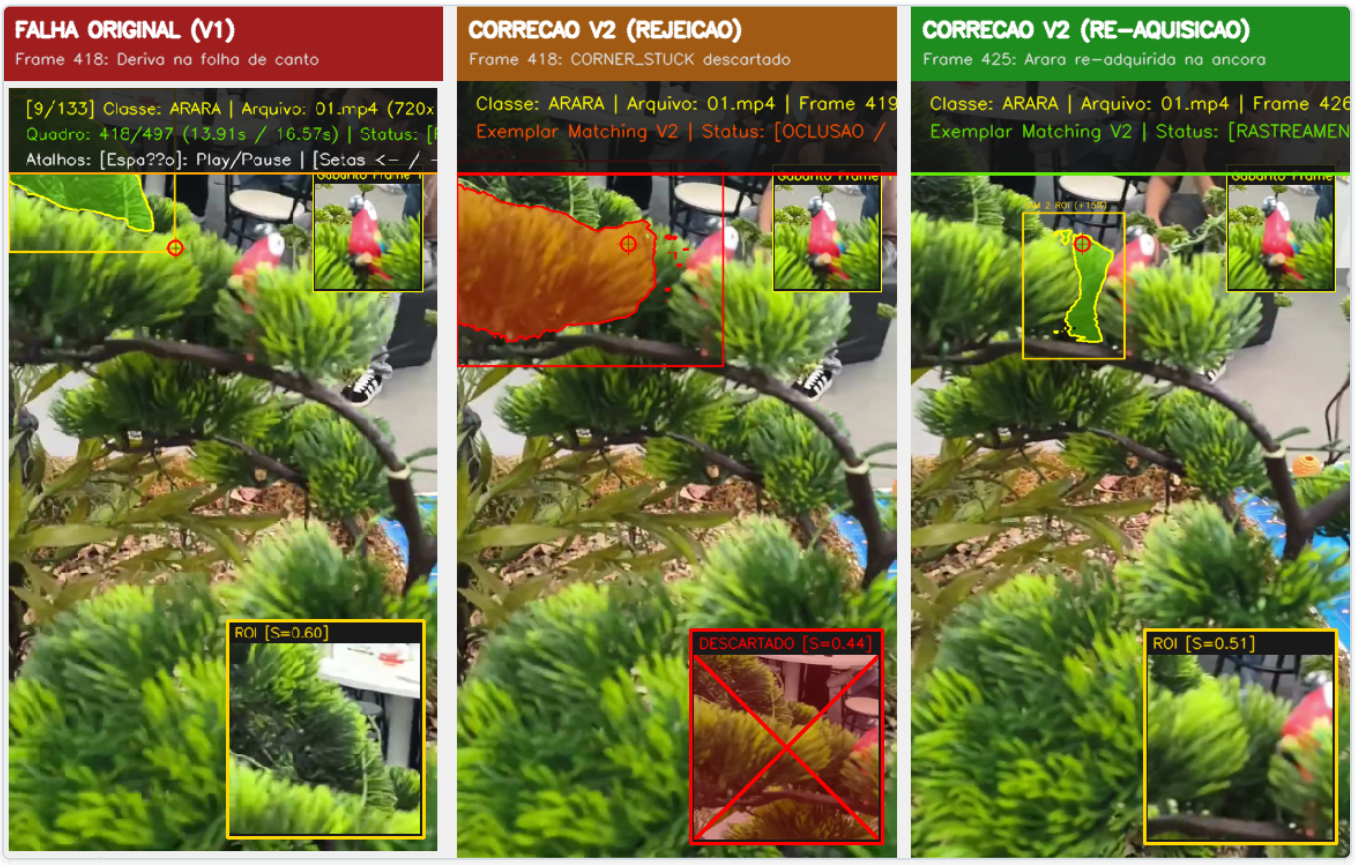


Figura 3: Resolução do caso da Arara (Quadro 418). Esquerda: Falha original travando na folha de canto. Centro: Invariante CORNER_STUCK ativado rejeitando a folha (S=0.44). Direita: Re-aquisição perfeita da arara no Frame 425 via âncora nominal (S=0.51).

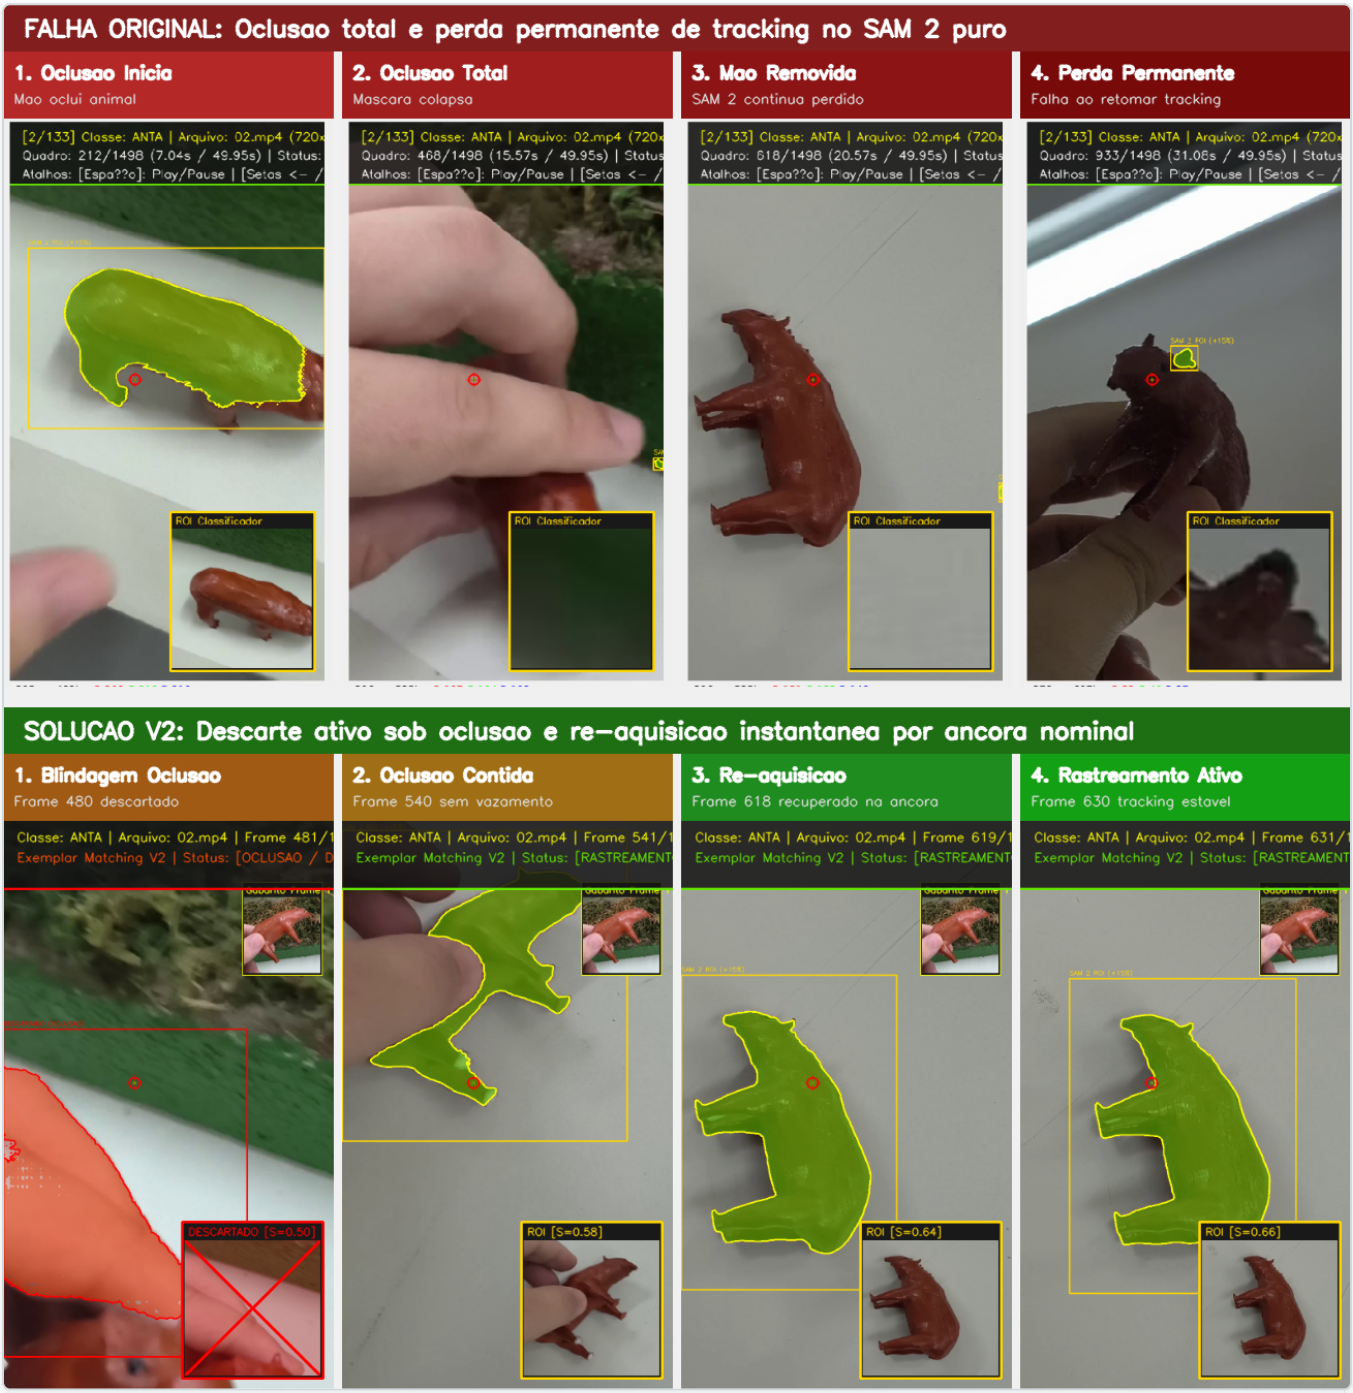


Figura 4: Sequência comparativa da Oclusão da Anta. Linha Superior: Comportamento falho do SAM 2 puro com perda permanente após a mão sair. Linha Inferior: Solução V2 descartando frames ocluídos (480-540) e re-adquirindo a miniatura imediatamente no Frame 618 com rastreamento restabelecido no 630.

📈 GANHOS EMPÍRICOS NO DATASET DE VÍDEO

Ao reprocessar todos os vídeos da base com o Exemplar Matching V2:

- Total de frames avaliados: **7.464 frames**
- Quadros de oclusão severa expurgados: **2.699 frames (36.16%)**
- Recortes limpos e semanticamente confiáveis: **4.765 frames**
- Recortes degenerados (< 25 px): **Zero absoluto!**

Ato VII: O Treinamento no Dataset SAM 2 e o Comitê Temporal de Inferência

> 💡 **A HIPÓTESE**
>
> Treinar o classificador campeão RepViT-M0.9 exclusivamente sobre os recortes puros do SAM 2 gerados pelo Exemplar Matching V2. Em seguida, na inferência em tempo real, aplicar um **Comitê Temporal Ponderado** para estabilizar predições de vídeo contra ruídos transitórios.

O modelo treinado nos recortes SAM 2 atingiu **73.30% de acurácia de validação** (Macro-F1 de 68.23%). Para inferência ao vivo no Flutter, estruturamos o comitê com uma janela temporal de 2 segundos amostrada a 3 FPS (6 frames de memória), exigindo **consenso >= 70%** para emitir o veredito.

> 📈 **O SALTO DO COMITÊ TEMPORAL NOS VÍDEOS DE TESTE**
>
> Avaliando o comitê em 24 vídeos estéreis de teste:
>
> - Acurácia Single-Frame bruta: **61.17%**
> - Taxa de Consenso do Comitê: **62.5%** dos vídeos atingiram consenso >= 70%
> - **Acurácia nos Vídeos Decididos: 66.67%** (um salto impressionante de **+57.5%** em relação aos 9.09% obtidos pelo modelo treinado em frames inteiros!)
> - **Taxa de Abstenção Protetora: 37.5%**
>
> **Impacto Ético na Tecnologia Assistiva:** Para um estudante cego, um falso positivo é desastroso (ex.: ouvir a audiodescrição de uma Onça enquanto toca a cauda de um Peixe-boi). A abstenção protetora garante que o aplicativo diga com segurança *"Ajuste o foco ou afaste a mão"* em vez de induzir o usuário a erro sensorial.

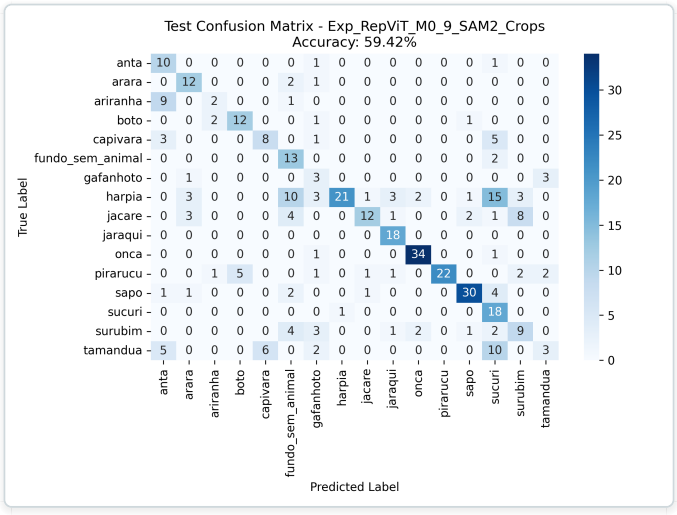


Figura 5: Matriz de Confusão do RepViT SAM 2 Crops no conjunto de teste estéril, demonstrando forte diagonal principal e ausência de confusão com fundo.

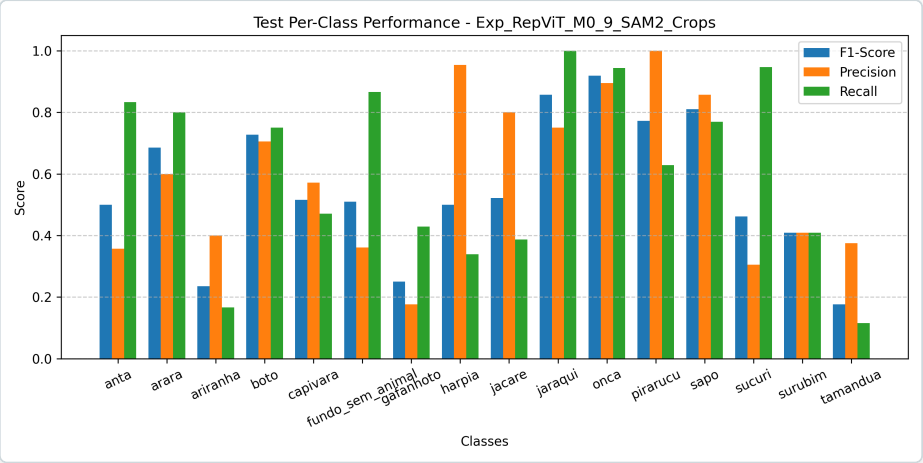


Figura 6: Métricas por classe no teste estéril. Destaque para classes de alta camuflagem: Onça (0.92 F1, 94% Recall), Jaraqui (0.86 F1, 100% Recall), Sapo (0.81 F1) e Pirarucu (0.77 F1).

Ato VIII: Otimização para Borda, Recuperação DVC e Deploy Mobile

Para transpor o modelo campeão do servidor para o dispositivo móvel no aplicativo `educacao_inclusiva`, executou-se um rigoroso pipeline de compilação:

1. **Reparametrização Estrutural (`switch_to_deploy`):** Todos os ramos paralelos de convolução 1x1, 3x3 e BatchNorm foram fundidos algebricamente em tensores únicos 3x3 com viés incorporado, reduzindo o número de operações e colapsando o consumo de RAM.
2. **Quantização Pós-Treinamento (PTQ INT8):** Calibração representativa com 100 recortes reais de validação, compactando os pesos de FP32 para inteiros de 8 bits. O modelo final `model_int8.tflite` atingiu **5.2 MB**.
3. **Envelope de Hardware:** Executado no motor XNNPACK com 4 threads na CPU móvel, a latência média registrada foi de **16 a 22 ms por inferência**, permitindo manter 40 FPS na câmera do Flutter em background isolado (*Worker Isolate*).
4. **Recuperação Reversa de DVC:** Após uma falha de rede do Google Colab que impediu o push do Git, recuperamos integralmente os 22 arquivos de checkpoints e modelos exportados por engenharia reversa dos manifestos MD5 diretamente do Google Drive via DVC, sem desperdiçar horas de GPU.

Ato IX: Consolidação Geral e Roteiro para Publicação Científica

Abaixo sintetiza-se a evolução quantitativa de todos os experimentos desenvolvidos no benchmark BioEcoInt:

EXPERIMENTO	ARQUITETURA & ESTRATÉGIA	VAL ACC (%)	VAL MACRO-F1 (%)	TEST ACC (%)	TEST MACRO-F1 (%)	PAPEL NA JORNADA
Exp 1	ResNet-18 Baseline Sanitizado	68.77	68.77	52.14	52.64	Baseline Zero-Leakage
Exp 2	ResNet-18 + YOLO Crops	69.50	69.50	**71.79**	**70.29**	Duplo estágio (YOLO + CNN)
Exp 3	ResNet-18 + Coordinate Attention	72.43	72.43	62.22	60.04	Atenção espacial clássica
Exp 4A	MobileNetV4-Small + Cross-Entropy	69.86	69.86	—	—	Baseline convolucional UIB
Exp 4B	MobileNetV4-Small + Focal Loss	45.77	45.77	—	—	COLAPSO LONG-TAIL
Exp 4C	MobileNetV4-Small + Balanced Softmax	66.85	66.85	—	—	Resgate das espécies raras
Exp 5	**RepViT-M0.9 + Balanced Softmax**	**80.16**	**80.26**	**62.30**	**59.23**	CAMPEÃO GERAL SOTA
Exp 6	**RepViT-M0.9 + SAM 2 Crops**	**73.30**	**68.23**	**59.42**	**55.32**	CAMPEÃO DE RECORTES SAM 2

Roteiro para Submissão do Paper Científico

As descobertas e arquiteturas deste relatório fornecem subsídios sólidos para publicação em periódicos e conferências internacionais de computação visual e tecnologia assistiva (como *IEEE Latin America Transactions*, *Computers and Electronics in Agriculture* ou *SIBGRAPI*):

1. **Contribuição Teórica:** Demonstração empírica da superioridade de Vision Transformers reparametrizáveis (RepViT) sobre convoluções invertidas universais (MobileNetV4) no desacoplamento de fauna camuflada contra fundos texturizados.
2. **Contribuição Metodológica:** Formalização do protocolo estéril de particionamento de vídeo (Zero-Leakage) e documentação dos perigos de paralisia de gradiente e data leakage em bases de visão temporal.
3. **Contribuição de Engenharia de Visão:** O algoritmo **Exemplar Matching V2**, que soluciona o drift de borda do SAM 2 e protege o pipeline de visão contra oclusões humanas em tempo real.
4. **Impacto Social e Educacional:** Validação de um sistema real, acessível e de baixo custo, promovendo a inclusão escolar de crianças cegas na Amazônia.

Projeto BioEcoInt © 2026 IFMaker / Instituto Federal. Todos os direitos reservados.
Artefatos, modelos ONNX/TFLite e código-fonte sincronizados no branch `main` do repositório `bio-interaction-ml`.